



Análisis y Modelado de Riesgo de Impago

Reporte de clasificación de clientes mediante algoritmos
supervisados

Autor: Alberth Pinco Bravo

Curso de Minería de Datos y Aprendizaje Automático

Julio de 2025

Resumen

Se desarrolló un modelo de clasificación para anticipar el riesgo de impago de clientes de una cooperativa financiera, a partir de datos históricos sociodemográficos y de comportamiento de pago. En primer lugar, se llevó a cabo un análisis exploratorio para identificar variables clave y obtener insights preliminares sobre las tendencias de clientes con riesgo de impago frente a aquellos sin riesgo. A continuación, se entrenaron cuatro modelos (Random Forest, regresión logística, árbol de decisión y XGBoost) mediante validación cruzada para evaluar su capacidad predictiva y ajustar sus hiperparámetros. Finalmente se comparó su desempeño sobre datos de prueba no vistos, dejando como mejor candidato al modelo de regresión logística por su capacidad para minimizar los falsos negativos, lo que reduce la probabilidad de otorgar crédito a clientes con riesgo de impago y de esta manera disminuir las pérdidas.

1. Objetivos

- Identificar tendencias en las características de clientes con riesgo de impago frente a aquellos sin riesgo.
- Comprender cuáles son las variables más relevantes para la decisión de otorgar un crédito.
- Entrenar un modelo de clasificación capaz de detectar clientes con riesgo de impago para optimizar el proceso de aprobación de crédito.

2. Descripción de los datos

Según el archivo `Data_Clientes_Cooperativa.txt`, el dataset contiene 4.117 observaciones y 11 variables:

- `id`
- `edad`
- `ingresos`
- `género`
- `estado civil` (married, single, div/sep/wid)
- `número de hijos`
- `número de tarjetas`
- `modalidad de pago` (weekly, monthly)
- `hipoteca` (yes/no)
- `número de préstamos`
- `riesgo` (variable objetivo)

3. Metodología

Para cada una de las fases se empleó el lenguaje de programación R en RStudio.

1. Preprocesamiento de datos: Se dejaron las diferentes variables en el formato correcto (variables categóricas en factores).
2. Análisis exploratorio: se visualizaron las distribuciones de cada variable en función del riesgo de impago.
3. División de datos: se realizó una partición estratificada del 85 % para entrenamiento y 15 % para prueba, preservando la proporción de clases (riesgo/no riesgo).
4. Entrenamiento de modelos: Se entrenaron cuatro modelos (Random Forest, regresión logística, árbol de decisión, XGBoost) mediante validación cruzada k -fold ($k=10$, 5 repeticiones) y búsqueda de hiperparámetros por *Grid Search*.

4. Análisis exploratorio

Para comenzar, se realizó una búsqueda de valores faltantes y posibles inconsistencias. De las 4.117 observaciones, el único valor faltante en la variable *género* fue imputado con la moda de los registros que comparten la misma clase de riesgo. No se presentaron más inconsistencias.

En la [Figura 1](#) se aprecia que las proporciones de impago para las variables *género*, *hipoteca* y *estado civil* son prácticamente idénticas entre clientes con y sin riesgo. Esto sugiere que estas tres variables individualmente aportan muy poca información discriminativa a la hora de clasificar el riesgo de impago.




Figura 1. Proporción de clientes con y sin riesgo de impago, segmentada por género, hipoteca y estado civil.

En cambio, variables como *número de préstamos*, *número de hijos* y *número de tarjetas* presentan patrones claramente distintos según la clase de riesgo (véase [Figura 2](#)). Mostrando por ejemplo que la proporción de impagos es mayor entre quienes no han solicitado nunca un préstamo y aquellos que no tienen hijos.




Figura 2. Proporción de clientes con y sin riesgo de impago, segmentada por número de préstamos, número de hijos y número de tarjetas.

Del mismo modo, las distribuciones de las variables *edad* e *ingresos* (véase [Figura 3](#)) nos muestran que los clientes de esta cooperativa que incurren en riesgo de impago tienden a ser considerablemente mayores y a presentar ingresos más altos que quienes no incurren en riesgo. Esta diferencia en las medianas (alrededor de 37 años vs. 26 años en edad, y unos 32000 vs. 23000 en ingresos) sugiere que ambos predictores son relevantes para distinguir potenciales morosos.




Figura 3. Proporción de la variable objetivo (riesgo), y boxplots de edad e ingresos según la clase de riesgo.

En resumen, este análisis exploratorio nos indica que las variables más relevantes para clasificar el riesgo de impago parecen ser los ingresos, la edad, el número de préstamos, el número de hijos e incluso el número de tarjetas. Mientras que variables como género, hipoteca y el estado civil muestran poca capacidad discriminativa y podrían excluirse para el entrenamiento de los modelos. Sin embargo, a continuación se implementan un Random Forest y una regresión logística para corroborar estos hallazgos.

5. Entrenamiento de modelos

Random Forest

Se entrenó un Random Forest de 500 árboles con un cross-validation (10-fold $\times$ 5 repeticiones) para afinar el número de variables muestreadas en cada división (`mtry`).

Con el modelo final (con parámetro óptimo `mtry=2`) se calculó la importancia de cada variable según la reducción media de Gini y de la exactitud (Figura 4). De este modo, tal como se evidenció en el análisis exploratorio, las tres variables con mayor relevancia son los ingresos, el número de préstamos y la edad, mientras que el género, la hipoteca y el estado civil conforman la parte inferior del ranking de importancia.




Figura 4. Importancia de variables en Random Forest (MeanDecreaseGini y MeanDecreaseAccuracy).

En cuanto al desempeño del Random Forest evaluado mediante el cross validation en el conjunto de entrenamiento, se obtuvieron los siguientes indicadores

- **Sensitivity:** 0.69
- **Specificity:** 0.92
- **Pos Pred Value:** 0.67
- **Neg Pred Value:** 0.92
- **F1-Score:** 0.68
- **Balanced Accuracy:** 0.80

Regresión Logística

Se ajustó un modelo saturado con todas las variables predictoras para evaluar la contribución de cada variable mediante un análisis de devianza (ANOVA). Esto evidenció que las reducciones de desviación más significativas corresponden a *ingresos* ($\Delta D = 579,42$) y *edad* ($\Delta D = 176,03$), lo que confirma su alta capacidad explicativa. En cambio, la variable *género* ($\Delta D = 0,11$), junto con la variable *hipoteca* ($\Delta D = 13,31$), apenas redujeron la desviación, situándose entre las predictoras menos relevantes.

A continuación se reentrenó un modelo logístico sin las variables *género* e *hipoteca*, y se determinó el punto de corte óptimo a partir de la curva ROC (véase [Figura 5](#)).




Figura 5. Curva ROC del modelo logístico en entrenamiento (CV), con punto de corte óptimo (0.233)

En cuanto al desempeño de este modelo logístico evaluado mediante cross validation (10-fold $\times$ 5 repeticiones) en el conjunto de entrenamiento, y con punto de corte en 0.233, se obtuvieron los siguientes indicadores

- **Sensitivity:** 0.75
- **Specificity:** 0.85
- **Pos Pred Value:** 0.55
- **Neg Pred Value:** 0.93
- **F1-Score:** 0.64
- **Balanced Accuracy:** 0.80

Árbol de clasificación

Se entrenó un árbol de decisión excluyendo las variables *género*, *hipoteca* y *estado civil*, y se realizó la poda de este según el valor de *cp* que minimiza el error de validación cruzada interna del propio algoritmo.

Como se ilustra en la [Figura 6](#), la primera partición del árbol se basa en la variable *ingresos*. Si un cliente posee ingresos superiores a 30.000 el modelo lo etiqueta inmediatamente como “riesgoso” (lo cual se ajusta a lo observado en el análisis exploratorio en la [Figura 3](#)), en cambio, los restantes (Ingresos < 30.000) son clasificados según el número de préstamos, quienes nunca han solicitado un préstamo son etiquetados como “riesgo”, mientras que aquellos con al menos un préstamo se consideran “no riesgo”.




Figura 6. Árbol de decisión podado según el parámetro de complejidad óptimo (*cp*).

En cuanto al desempeño de este árbol de decisión evaluado mediante el cross validation en el conjunto de entrenamiento, se obtuvieron los siguientes indicadores

- **Sensitivity:** 0.63
- **Specificity:** 0.93
- **Pos Pred Value:** 0.67
- **Neg Pred Value:** 0.91
- **F1-Score:** 0.65
- **Balanced Accuracy:** 0.78

XGBoost

Se entrenó un xgboost sin las variables *género*, *hipoteca* y *estado civil*, con un cross-validation (5-fold $\times$ 3 repeticiones) para afinar distintos hiperparámetros como el número de árboles, la profundidad máxima de cada árbol, la tasa de aprendizaje y el costo de complejidad por split. Con la mejor combinación de estos hiperparámetros se obtuvieron los siguientes indicadores (según la validación cruzada)

- **Sensitivity:** 0.66
- **Specificity:** 0.92
- **Pos Pred Value:** 0.67
- **Neg Pred Value:** 0.92
- **F1-Score:** 0.67
- **Balanced Accuracy:** 0.79

6. Resultados sobre el Conjunto de Prueba

Para cuantificar la capacidad de generalización de los diferentes modelos, se utilizó el 15 % de los datos reservado al inicio (conjunto de prueba), que permaneció completamente apartado durante el ajuste y la validación cruzada. Para este conjunto de datos se obtuvieron los siguientes resultados:

	R_Forest	LogReg	Tree	XGB
Sensitivity	0.61	0.71	0.61	0.59
Specificity	0.94	0.88	0.94	0.94
Pos Pred Value	0.71	0.58	0.72	0.71
Neg Pred Value	0.91	0.93	0.91	0.91
F1	0.65	0.64	0.66	0.65
Balanced Accuracy	0.77	0.79	0.77	0.77

Tabla 1. Desempeño de los modelos en el conjunto de prueba.

Cabe destacar que el random forest, el xgboost y el árbol de decisión exhiben un desempeño prácticamente idéntico, donde todos alcanzan una alta especificidad y una buena precisión tanto en la predicción de positivos como de negativos. Sin embargo, por su sencillez e interpretabilidad, el árbol de decisión individual resulta suficiente, lo que permite prescindir del random forest y el xgboost.

En contraste, la regresión logística ofrece la mayor sensibilidad de los cuatro modelos, a costa de una especificidad ligeramente inferior (aunque aún muy alta). Además, muestra la mejor capacidad para predecir correctamente los negativos (Neg Pred Value), mientras que su precisión en la predicción de positivos (Pos Pred Value) es ligeramente menor que la de los métodos basados en árboles.

7. Conclusiones

Los ingresos, el número de préstamos y la edad son las variables más significativas para clasificar a un cliente como riesgoso. Además, en este conjunto de datos se observa que los clientes con mayor probabilidad de impago tienden a presentar niveles de ingresos elevados.

En cuanto a los modelos, tanto la regresión logística como el árbol de decisión mostraron un desempeño satisfactorio para clasificar el riesgo de impago. Sin embargo, la regresión logística resulta especialmente adecuada cuando la prioridad es **minimizar los falsos negativos**, es decir, identificar correctamente a los clientes de alto riesgo (sensibilidad = 0.71), lo que ayuda a prevenir pérdidas. No obstante, esto conlleva un aumento de falsos positivos (PPV = 0.58), lo que implicaría rechazar clientes solventes y perder posibles oportunidades de negocio.

Una estrategia recomendada es emplear la regresión logística como **filtro inicial** para identificar la mayoría de clientes riesgosos y someter a estos a una segunda evaluación para descartar falsos positivos antes de tomar la decisión final.